

I. FUNDAMENTOS DEL ANÁLISIS DESCRIPTIVO DE DATOS UNIDIMENSIONALES

→ Máster en Bioestadística y Bioinformática



CENTRO
EUROPEO
DE MÁSTERES
Y POSGRADOS

Índice

1.	El análisis descriptivo	5
2.	El Dataset de trabajo	6
3.	Medición del volumen de los datos	8
4.	Medición de las variables	10
5.	Medidas estadísticas	12
6.	Medidas de centralidad	14
7.	Medidas de posición	17
8.	Medidas de dispersión I	20
9.	Medidas de dispersión II	21
10.	Cálculo de medidas	24

Objetivos

- Conocer el concepto de análisis descriptivo y sus objetivos.
- Conocer las principales métricas del volumen o tamaño de datos.
- Entender intuitivamente dos distribuciones que suelen aparecer en los datos: la distribución normal y la Ley de Zipf.
- Conocer las principales medidas de centralidad de los datos: media, mediana y moda.
- Conocer las principales medidas de posición de los datos: cuartiles, deciles, percentiles, máximo y mínimo.
- Conocer las principales medidas de dispersión de los datos: recorrido, rango intercuartílico, desviación típica y varianza.
- Entender la complejidad del cálculo de estas medidas.
- Comprender algunos de los tipos de gráficos básicos como el diagrama de caja.

Ideas clave

- El objetivo del **análisis descriptivo** de los datos consiste en comprender cómo están distribuidos y qué problemas presentan estos, con el fin de entenderlos mejor y ser capaz de resolverlos. Para ello, este análisis se apoya en el uso de **métricas** que caracterizan a los datos, y de **gráficas** que permiten entender la distribución de los datos de manera manual.
- Las **métricas de volumen** pueden ser lógicas (como el número de filas o de columnas), o físicas (como el espacio ocupado en disco).
- Las **métricas de variables** son de tres tipos: centralidad, posición y dispersión.
- Las medidas de **centralidad** indican los valores más representativos de un conjunto de datos. Los ejemplos más notables de estas medidas son la media, la mediana y la moda.

- ▣ Las medidas de **posición** nos informan del lugar que ocupa un dato dentro de un conjunto ordenado de valores. Las medidas más relevantes de este tipo son los **cuartiles**, los **deciles**, los **percentiles**, el **máximo** y el **mínimo**.
- ▣ Las medidas de **dispersión** se utilizan para medir el grado de dispersión o variabilidad que existe en la distribución. Algunas medidas de este tipo son el **recorrido**, el **rango intercuartílico**, la **varianza** o la **desviación típica**.
- ▣ Algunas **distribuciones notables** por su continua aparición en los análisis estadísticos son la distribución normal y la ley de Zipf. La **distribución normal** da lugar a una gráfica llamada la campana de Gauss. La **ley de Zipf** tiene que ver con la frecuencia de los datos y da lugar a una gráfica hiperbólica. Otro gráfico que ayuda a caracterizar a las variables es el **diagrama de caja** o boxplot, relacionado directamente con los cuartiles.

1. El análisis descriptivo

En este tema abordamos el primero de los pasos que se debe efectuar en todo análisis de datos, que se suele conocer como **análisis descriptivo**. El objetivo de este es comprender cómo están distribuidos los datos y qué problemas presentan, con el fin de entenderlos mejor y ser capaces de resolver dichos problemas.

El análisis descriptivo se aborda desde dos puntos de vista:

- **Métricas o medidas descriptivas:** el uso de métricas que caracterizan los datos, y que, de alguna manera, los resumen.
- **Gráficas:** el uso de gráficas que permiten entender la distribución de los datos de manera visual.

El objetivo de este tema no es realizar un recorrido exhaustivo por la estadística descriptiva, por lo que no vamos a ser cien por ciento rigurosos en la presentación de definiciones y fórmulas, sino que vamos a adoptar un **enfoque práctico**. Este enfoque es, normalmente, suficiente para entender los datos que se manejan en la práctica y resolver sus problemas.

Para abordar el análisis descriptivo, vamos a utilizar un conjunto de datos o *dataset* de ejemplo, obtenido del paquete *datasets* de R. Se trata del conjunto denominado *Iris*, introducido por Ronald Fisher en su artículo de 1936. Este contiene 50 muestras de tres especies diferentes de iris, proporcionando información acerca de variables como la longitud del pétalo. Dicho *dataset* es frecuentemente utilizado para explicar técnicas de minería de datos y de *Machine Learning*, pues es lo suficientemente sencillo como para que el significado de sus variables sea comprendido fácilmente, y a la vez lo suficientemente complejo como para que sobre él puedan ser aplicados con éxito algoritmos de clasificación o de regresión, algunos de los cuales se verán más adelante en el curso.

2. El Dataset de trabajo

Antes de comenzar con una descripción del conjunto de datos de *Iris*, recordemos brevemente la forma en la que se suele presentar este tipo de objetos en cualquier disciplina, ya sean las Matemáticas, la Estadística o la Biología. Generalmente, un *dataset* se presenta en forma de tabla de dos dimensiones. Sus elementos fundamentales son las filas y las columnas, que tienen el siguiente significado:

- Las filas hacen referencia a los **individuos, observaciones, ejemplos o registros**: por ejemplo, si estamos midiendo la altura y el peso de diferentes personas, cada fila estaría asociada a una persona concreta.
- Las columnas hacen referencia a las **variables, características** (del inglés *features*) o **dimensiones**: en el ejemplo previo, tendríamos dos columnas, una que contendría las alturas de los distintos individuos y otra que contendría los pesos.

El conjunto de datos *Iris* contiene 150 observaciones y 5 variables. Es decir, está definido por una tabla o matriz con 150 filas y 5 columnas. Cada una de las filas hace referencia a una planta de iris de la que se han tomado los valores de 5 variables. A continuación se muestran las 10 primeras filas de este *dataset*.

Longitud del sépalo (cm)	Anchura del sépalo (cm)	Longitud del pétalo (cm)	Anchura del pétalo (cm)	Tipo de especie
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3.0	1.4	0.2	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa
5.0	3.6	1.4	0.2	Iris-setosa
5.4	3.9	1.7	0.4	Iris-setosa
4.6	3.4	1.4	0.3	Iris-setosa
5.0	3.4	1.5	0.2	Iris-setosa
4.4	2.9	1.4	0.2	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa

De izquierda a derecha en la tabla anterior, el significado de las 5 variables es el siguiente:

- 1) **Longitud del sépalo** de la planta en cuestión. Es una variable numérica medida en centímetros.
- 2) **Anchura del sépalo** de la planta en cuestión, variable numérica medida en centímetros.
- 3) **Longitud del pétalo** de la planta en cuestión, variable numérica medida en centímetros.

- 4) **Anchura del pétalo** de la planta en cuestión, variable numérica medida en centímetros.
- 5) **Tipo de especie** de iris al que pertenece la planta en cuestión: es una variable categórica con tres niveles, *Setosa*, *Versicolor* y *Virginica*.

Como vemos, se trata de un conjunto de datos que contiene variables tanto categóricas como numéricas. Esto es altamente deseable, ya que permite utilizar el mismo para la ilustración de una gran variedad de procedimientos estadísticos, como se verá más adelante.

Veremos en profundidad los distintos tipos de variables más adelante. Por ahora, llega con conocer que las variables numéricas son aquellas que toman como valores números reales en general (se dividen en variables discretas, que toman valores enteros, y variables continuas, que toman valores reales que no tienen por qué ser enteros), y las variables categóricas, que son aquellas que toman como valores distintas categorías u etiquetas.

3. Medición del volumen de los datos

Las métricas o medidas más básicas que se pueden aplicar a un conjunto de datos miden su **volumen**, tamaño o dimensiones. En concreto, podemos centrarnos en medidas lógicas o físicas:

- ❑ Las **medidas lógicas** se centran en el número de elementos lógicos que definen a los datos.
- ❑ Las **medidas físicas** caracterizan los datos en términos del espacio que ocupan en disco.

En lo que respecta a las medidas lógicas, las más importantes son las siguientes:

- ❑ **Número de ejemplos**, registros o filas: en el caso del conjunto de datos *Iris*, disponemos de una tabla con 150 filas que se corresponden a los estudiantes.
- ❑ **Número de variables**, columnas o dimensiones: en el *dataset* de ejemplo tenemos 5 variables.
- ❑ **Número de posibles valores para las variables**: en el *dataset Iris* se cuenta con 4 variables numéricas, que podrían tomar, en principio, cualquier valor positivo (sujeto evidentemente a las limitaciones físicas del tamaño de un sépalo o pétalo), y una variable numérica, que puede tomar 3 valores (categorías) distintos.

Se debe tener en cuenta que las dimensiones lógicas de nuestros conjuntos de datos pueden variar con el tiempo. Por ejemplo, podría darse el caso de que el conjunto de datos de *Iris* fuese actualizándose constantemente, y de que cada día añadiésemos datos adicionales sobre nuevas plantas de las que se han tomado medidas. Por otra parte, es posible generar columnas sintéticas a partir de los datos originales para efectuar cálculos relevantes, que podrían ser de interés para aplicar ciertos métodos estadísticos. Por ejemplo, podría darse el caso de que nos interesase crear una columna adicional que contuviese (para cada individuo), el valor promedio de las 4 variables numéricas originales.

Por otro lado, la medida física más habitual es el número de *bytes/megabytes/etc.* que ocupa nuestro *dataset*. En nuestro caso, se trata de un archivo que en formato CSV (*comma-separated values*), ocupa 5107 *bytes*, es decir, es un archivo pequeño.

El formato de archivo CSV es muy habitual, y lo utilizaremos a menudo durante el curso cuando carguemos archivos de datos mediante el *softwareR*. Como apunte adicional, las primeras filas del *dataset Iris* en formato CSV tendrían el siguiente aspecto.


```
Id,SepalLengthCm,SepalWidthCm,PetalLengthCm,PetalWidthCm,Species
1,5.1,3.5,1.4,0.2,Iris-setosa
2,4.9,3.0,1.4,0.2,Iris-setosa
3,4.7,3.2,1.3,0.2,Iris-setosa
4,4.6,3.1,1.5,0.2,Iris-setosa
5,5.0,3.6,1.4,0.2,Iris-setosa
6,5.4,3.9,1.7,0.4,Iris-setosa
7,4.6,3.4,1.4,0.3,Iris-setosa
8,5.0,3.4,1.5,0.2,Iris-setosa
9,4.4,2.9,1.4,0.2,Iris-setosa
10,4.9,3.1,1.5,0.1,Iris-setosa
```

Conjunto de datos de Iris en formato CSV. Fuente: elaboración propia


4. Medición de las variables

La lógica indica que, para distintos tipos de variables, dispondremos de distintas métricas para caracterizarlas. Por ejemplo, para las variables categóricas, la moda es la principal medida de centralidad. Sin embargo, las variables numéricas se suelen caracterizar a través de la media.

Revisaremos los tipos de medidas para las distintas variables más adelante en esta unidad. Sin embargo, antes de hacerlo, conviene que nos familiaricemos con dos **distribuciones** que aparecerán frecuentemente en nuestros datos. Las presentamos a continuación.

DISTRIBUCIÓN NORMAL O CAMPANA DE GAUSS

Es interesante presentar de manera intuitiva la distribución normal o **campana de Gauss**, que caracteriza la probabilidad de aparición de los datos y que se trata de una de las curvas o funciones más frecuentes de la historia de las Matemáticas y de los fenómenos físicos en general. Esta curva aparece en escenarios tan diferentes como los caracteres morfológicos de individuos como la estatura, o los caracteres fisiológicos como el efecto de un fármaco.




Histograma de la variable anchura del sépalo junto con una campana de Gauss. Fuente: elaboración propia.

En el gráfico que se muestra arriba a la izquierda podemos ver un histograma de la variable anchura del sépalo, realizada con el paquete *ggplot2* de R. Sobre el mismo se ha superpuesto la función que define una distribución normal. La figura ilustra claramente cómo esta distribución proporciona una buena aproximación de los datos. La campana de Gauss se analizará de manera más rigurosa posteriormente en el curso.

LEY DE ZIPF

La **ley de Zipf** aparece también con mucha frecuencia en los fenómenos naturales, y establece que, al ordenar los datos por su frecuencia o número de apariciones, se genera una hipérbola en la que los primeros valores son muy frecuentes, mientras que existe a la larga una gran cantidad de datos poco frecuentes, llamada habitualmente cola o tail.

Ilustremos la ley de Zipf, de nuevo, mediante la variable anchura del sépalo. Aunque se trata de una variable numérica, que en principio podría tomar cualquier valor, los datos han sido truncados a una cifra decimal, lo que nos facilitará nuestra tarea (en otro caso hubiese sido necesario agrupar los datos por intervalos). Representemos un diagrama de barras indicando la frecuencia o número de apariciones de cada valor de la variable anchura del sépalo en el conjunto de datos *Iris*. La figura se muestra en la parte de abajo.




Ley de Zipf en la variable anchura del sépalo. Fuente: elaboración propia.

Podemos apreciar que existen ciertos valores que aparecen con una alta frecuencia. Por ejemplo, hay en el conjunto de datos más de 25 plantas cuyo sépalo mide unos 3 centímetros de ancho. Por el contrario, las plantas cuyo ancho de sépalo supera los 4 centímetros constituyen una minoría. En definitiva, la ley de Zipf se está verificando en la variable analizada.

5. Medidas estadísticas

Para entender y caracterizar los datos, es preciso obtener una serie de medidas sobre los mismos que nos indiquen cómo están distribuidos. La estadística descriptiva se encarga de proporcionar una serie de medidas con este fin, que se pueden agrupar en tres grandes familias, como se ve en la siguiente figura.



Tipos de medidas estadísticas. Fuente: elaboración propia

- ❑ Las medidas de **centralidad** indican los valores más representativos de un conjunto de datos. Los ejemplos más notables de estas medidas son la media, la mediana y la moda.
- ❑ Las medidas de **posición** nos informan del lugar que ocupa un dato dentro de un conjunto ordenado de valores. Las medidas más relevantes de este tipo son los cuartiles, los percentiles, el máximo y el mínimo.
- ❑ Las medidas de **dispersión** se utilizan para medir el grado de variabilidad que existe en la distribución. Algunas medidas de este tipo son el recorrido, el rango intercuartílico, la desviación típica o la varianza.

Como ya hemos señalado previamente, aunque en esta unidad no pretendemos ser rigurosos, conviene destacar que estas medidas tienen una sólida base matemática y una profunda relación con las curvas que hemos visto previamente. Por ejemplo, la media y la desviación típica son los parámetros principales de la distribución normal, la campana de Gauss. Si denotamos como μ a la media y como σ a la desviación típica, la campana de Gauss vendría dada por la siguiente función:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in \mathbb{R}.$$

Esta distribución tiene una forma de campana, como hemos visto previamente, y cumple propiedades muy valiosas desde el punto de vista del análisis estadístico, como por ejemplo:

- En el intervalo $[\mu - \sigma, \mu + \sigma]$, se encuentran comprendidos, aproximadamente, el 68.26% de los datos.
- En el intervalo $[\mu - 2\sigma, \mu + 2\sigma]$, se encuentran comprendidos, aproximadamente, el 95.44% de los datos.
- En el intervalo $[\mu - 3\sigma, \mu + 3\sigma]$, se encuentran comprendidos, aproximadamente, el 99.74% de los datos.

Las propiedades previas se pueden aplicar, por ejemplo, en la **detección de datos atípicos**, que son aquellos que se alejan excesivamente del resto.

Conviene reseñar que la distribución normal de referencia es la **normal estándar**, que es la distribución normal que tiene media 0 y desviación típica 1.

6. Medidas de centralidad

Las medidas de centralidad tienen como objetivo indicar el **valor más representativo** de un conjunto de cantidades. Las tres medidas de centralidad más importantes son la media, la moda y la mediana.

MEDIA

La media es el valor obtenido al sumar todos los datos y dividir el resultado entre el número de datos. Así, si tenemos n datos y estos toman los valores x_i , con $i = 1 \dots n$, la media, que se suele denotar como $\bar{x}$, se calcula a través de la siguiente fórmula:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

La media presenta las siguientes características:

- ❑ Esta medida sólo se puede aplicar a variables numéricas, ya sean discretas o continuas.
- ❑ Si los datos vienen dados en forma de tabla de frecuencias, se calcula multiplicando cada dato por su frecuencia (número de apariciones) y dividiendo entre la suma de todas las frecuencias.
- ❑ Como indica la lógica, la media no tiene por qué ser un dato válido. Por ejemplo, en una variable que sólo puede tomar valores enteros, es muy frecuente que la media sea un valor real, y, por tanto, no válido para la variable.
- ❑ Se trata de una medida muy poco estable o robusta. Por ejemplo, supongamos que tenemos los siguientes valores para una variable, $\{1,2,3,1,1,2,2,10000\}$. La media toma, en este caso, el valor 1251.5, que es un valor que no representa bien a la mayoría de nuestros datos, que se encuentran comprendidos entre 1 y 3.

MEDIANA

La mediana es el valor central de un conjunto ordenado de datos. Para calcularla, se ordenan los valores en orden creciente y se toma el que ocupa el lugar central si el número de valores es impar, o la media de los dos centrales si es par. Estas son algunas de sus características:

- ❑ Como la media, es una métrica que sólo se puede aplicar a valores numéricos, porque puede ser necesario calcular una media. Por ejemplo, supongamos que una variable categórica sólo puede tomar los valores A y B . Aun asumiendo que existe un orden, por ejemplo, $A < B$, la mediana del conjunto $\{A, A, A, B, B, B\}$ no tendría sentido.
- ❑ La mediana se considera a veces una medida de posición, porque indica el valor que ocupa el lugar central.

- ❗ De igual manera que la media, su valor no tiene por qué ser un dato válido para la variable en cuestión.
- ❗ Se trata de una medida mucho más robusta que la media, es decir, menos sensible a datos atípicos. Se usa con frecuencia como complemento o en lugar de la media. En el ejemplo del conjunto $\{1,2,3,1,1,2,2,10000\}$, la mediana sería 2, cantidad que describe bastante bien al conjunto.

MODA

La moda es el valor que más se repite en un conjunto de datos. Algunas de sus propiedades son las siguientes:

- ❗ Es una medida que se puede aplicar a variables categóricas o numéricas, aunque es posible que no tenga mucho sentido en variables continuas, dependiendo de la precisión de nuestro formato (puede ocurrir que no existan valores repetidos). Se usa frecuentemente como alternativa a la media al tratar con variables categóricas.
- ❗ La moda siempre es un dato válido, porque es uno de los valores que toma nuestra variable.
- ❗ Se trata de una medida bastante estable, porque la aparición de un dato extremo aislado no la afecta en absoluto.
- ❗ Puede haber varias modas, en cuyo caso se habla de un conjunto de datos bimodal o multimodal.

Las medidas anteriores son muy valiosas para describir a los datos, aunque no nos dan una idea de su concentración o dispersión. Por ello, usamos también otro tipo de medidas o nos apoyamos en gráficas.

Ejemplo práctico: cálculo de medidas de centralidad en el dataset Iris

Recordemos que el conjunto de datos Iris dispone de 4 variables numéricas y una variable categórica. Calculemos las medidas de centralidad para dos de las variables numéricas, la longitud y la anchura del sépalo, y para la variable categórica, el tipo de especie.

- ❗ **Variable longitud del sépalo:** la media de esta variable toma el valor de 5.84 cm, mientras que la mediana, de 5.8 cm. Vemos que, en este caso, ambas medidas son muy similares, por lo que nos llevarían a la misma conclusión. Por otro lado, la moda de esta variable es 5 cm. Recordemos que la moda es el valor más repetido. En este caso, su cálculo es posible porque la variable viene dada con una precisión de un decimal, por lo que hay varios valores que se repiten. En concreto, existen 10 plantas cuyo sépalo mide 5 cm.
- ❗ **Variable longitud del pétalo:** el valor de la media es, en este caso, 3.76 cm. La mediana vale 4.35 cm. Al contrario que en el caso previo, la diferencia entre la media y la mediana aquí es considerable. Probablemente la media se encuentre afectada por

ciertos valores atípicos. Por el contrario, la mediana es una medida robusta, como ya se ha visto, y no sufre ante tales situaciones. Existen dos modas en esta variable, 1.4 y 1.5 cm. Ambas aparecen exactamente 13 veces en el conjunto de datos. Estamos, por tanto, ante una variable bimodal.

- ▮ **Variable tipo de especie:** se trata de una variable categórica, por lo que no tendría sentido calcular la media o la mediana. La variable tiene tres categorías: Setosa, Versicolor y Virginica. Existen 50 plantas en el *dataset* relativas a cada una de las tres categorías. Por tanto, las tres categorías son una moda y estamos ante una variable multimodal.

Como nota adicional, destacar que el cálculo de estas medidas no se realiza a mano lógicamente, sino a través de herramientas de software específicas. Más adelante veremos cómo se pueden obtener estas medidas utilizando R.

7. Medidas de posición

Las medidas de posición ayudan a entender la **estructura de los datos**, y son las que nos indican qué lugar ocupa un dato dentro de un conjunto ordenado de valores. Por tanto, son medidas que sólo se pueden aplicar a valores que admitan ordenación, típicamente a las variables numéricas. Las dos medidas más simples de este tipo son el máximo y el mínimo, pero se suelen utilizar con mucha frecuencia los cuartiles, los deciles y los percentiles.

El **máximo** y el **mínimo** tienen la definición obvia. Nos dan una primera aproximación a la distribución, pero son medidas muy **sensibles** a la presencia de valores extremos, por lo que en la mayoría de *datasets* no son muy representativas. Como consecuencia, se suelen usar con más frecuencia los cuartiles, los deciles o los percentiles. Estas medidas de posición se obtienen ordenando los datos y seleccionando los valores concretos que dejan a un lado un porcentaje concreto de los mismos, y al otro lado, el restante. Por ejemplo:

- El **primer cuartil** (o cuartil de orden 0.25) deja a su izquierda el 25% de los datos, y a su derecha el 75% restante.
- El **primer decil** (o percentil de orden 0.10) deja a su izquierda el 10% de los datos, y a su derecha el 90% restante.
- El **tercer percentil** (o percentil de orden 0.03) deja a su izquierda el 3% de los datos, y a su derecha el 97% restante. Muchas veces se utiliza el término percentil de la siguiente manera: dado un número real $0 < p < 1$, el percentil de orden p es el valor que deja a su izquierda el $100 \times p$ % de los datos. Por ejemplo, el percentil de orden 0.215 sería el valor que deja a su izquierda el 21.5% de los datos. En muchos textos, a esta definición de percentil se le conoce como **cuantil**.

De entre los elementos previos, los cuartiles son probablemente los más utilizados. Estos se denotan por Q_1 , Q_2 y Q_3 , y son los datos que ocupan, respectivamente, las posiciones del redondeo de $(n + 1)/4$, $2(n + 1)/4$ y $3(n + 1)/4$, respectivamente, en su versión más sencilla. Fijémonos que el valor de Q_2 coincide con la mediana, que se trata, por tanto, de una medida de centralidad y de dispersión.


Veamos un ejemplo. Sea el conjunto de datos $\{2, 3, 4, 5, 6, 7, 9\}$, que ya presentamos ordenado de manera creciente. En este caso, tenemos 9 observaciones, por tanto $n = 7$. Hemos visto que Q_1 es el dato que ocupa la posición $(n + 1)/4$, es decir, la posición 2, en este caso. En consecuencia, el primer cuartil toma el valor de 3. El segundo cuartil (la mediana) es el dato que ocupa la posición 4, es decir, 5. Finalmente, el tercer cuartil es el dato asociado a la posición 6, es decir, 7.

Las medidas de posición como los cuartiles, deciles y percentiles, al igual que ocurre con la mediana, son considerablemente más robustas que la media. En otras palabras, son más estables de cara a la aparición de valores extremos, que no les afectan demasiado. Por ello,

se suelen utilizar con frecuencia para detectar valores anómalos o atípicos. Supongamos que al conjunto de datos anterior le añadimos el valor 10000, es decir, el nuevo conjunto es el siguiente: $\{2,3,4,5,6,7,9,10000\}$. La media del nuevo conjunto de datos no es en absoluto representativa de la mayoría de valores del mismo. Sin embargo, Q_1 , Q_2 y Q_3 no han variado con respecto la situación previa (en este caso, como $n = 9$, para obtener las posición de los cuartiles, tendríamos que redondear). Así, la introducción de un dato claramente extremos no ha afectado a estas métricas.

Ejemplo: representación de boxplots en el conjunto de datos Iris

Veamos cómo se distribuyen las cuatro variables numéricas presentes en el dataset Iris por medio de un boxplot.



Boxplot de las variables de Iris. Fuente: elaboración propia

Este se muestra en la figura anexa. La forma de interpretar el gráfico es la siguiente. Existen cuatro colores, cada uno de los cuales representa a una variable numérica. Los valores de cada variable se representan sobre el eje y . La caja central hace referencia al conjunto de valores que se encuentran entre los cuartiles Q_3 y Q_1 . La longitud de la caja medida de manera vertical es el valor del rango intercuartílico. La línea horizontal en el medio de cada caja representa la mediana de la variable. Las líneas de los extremos representan el restante 50% de los valores de la variable (bien mayores que Q_3 , bien menores que Q_1). Los puntos negros hacen referencia a valores extremos u atípicos, que se alejan considerablemente de la mediana de la variable. Podemos observar, por ejemplo, que para la variable anchura del sépalo, el 50% de valores centrales se encuentran muy concentrados en torno a la mediana (que vale 3 cm). Además, existen unos cuantos valores atípicos. En cambio, la variable longitud del pétalo presenta bastante dispersión, pues existe una cantidad considerable de valores que se aleja de la mediana, en mayor grado hacia el extremo inferior. Esta variable, en cambio, no presenta valores extremos.

Ejemplo práctico: cálculo de medidas de posición en el dataset Iris

Calculemos, a modo ilustrativo, algunas medidas de posición para dos de las variables numéricas del conjunto de datos de Iris.

- ▮ **Variable anchura del sépal:** el mínimo y máximo valor de esta variable son, respectivamente, 2 y 4.4 cm. Por otra parte, el primer y tercer cuartil toman los valores respectivos de 2.8 y 3.3 cm. En consecuencia, aunque los datos se mueven en un rango de 2.4 cm, un 50% de los mismos se encuentra comprendido en un rango de solamente 0.5 cm. Como se ha comentado, el máximo y el mínimo son muy sensibles a la presencia de valores extremos, por lo que, en muchas ocasiones, no son demasiado representativos.
- ▮ **Variable anchura del pétalo:** en este caso, el mínimo es 0.1 cm, y el máximo, 2.5 cm. Q_3 y Q_1 toman los valores respectivos de 0.3 y 1.8 cm. En este caso, la discrepancia entre el mínimo y el máximo y el primer y el tercer cuartil es mucho menor que en el caso previo, por lo que podríamos encontrarnos ante una variable que no presenta valores extremos.

8. Medidas de dispersión I

Las medidas de dispersión, como su propio nombre indica, están orientadas a medir el **grado de dispersión** que existe en una variable. Estas medidas nos dan una idea de cómo de agrupados están los datos, y son complementarias y están relacionadas con las medidas de posición, que también pretenden aproximar esta idea. Las medidas de dispersión más populares son el recorrido, el rango intercuartílico, la desviación típica y la varianza.

RECORRIDO O AMPLITUD

El **recorrido** o **amplitud** está definido como el valor absoluto de la diferencia entre el máximo y el mínimo. Como estas dos medidas, es muy sensible a la presencia de valores extremos. Por ejemplo, si disponemos de un conjunto de 100 números en el que el mínimo es 1, el máximo es 1000, pero todos los demás son 2, el recorrido es 999, pero casi todos los datos están concentrados en torno al mínimo. Obviamente, en este conjunto, el máximo es un valor extremo o atípico.

RANGO INTERCUARTÍLICO

El **rango intercuartílico** es el valor absoluto de la diferencia entre el primer y el tercer cuartil, es decir, $|Q_3 - Q_1|$. También da una idea de cómo de próximos o separados están los datos, pero es una medida mucho más estable que el recorrido porque se basa en medidas estables, que son los cuartiles.

Los cuartiles y el rango intercuartílico se suelen expresar gráficamente a través de un **diagrama de caja** o **boxplot**, que permite visualizar cómo se distribuyen los datos de una manera intuitiva.

9. Medidas de dispersión II

Otras medidas de dispersión muy importantes son la **varianza** y la **desviación típica**. La varianza se define como la media de las diferencias entre cada valor y la media al cuadrado. Si la media de los n datos de una variable es $\bar{x}$, y cada valor de la variable es x_i , la varianza vendría dada por la siguiente fórmula:

$$\overline{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Como se puede observar, la varianza se suele denotar por medio de $\overline{\sigma}^2$, y la razón de ser el promedio del cuadrado de las diferencias es para garantizar que los **valores son positivos**, de manera que no se compensen las diferencias positivas con las negativas. Es decir, se tienen en cuenta las diferencias absolutas. El tomar los valores al cuadrado hace que el valor de la varianza sea relativamente grande comparándolo con los valores de la propia variable, por lo que se introduce la desviación típica como la raíz cuadrada de la varianza. La desviación típica tiene un valor comparable con los propios datos de la variable.

Como apunte adicional, destacamos la diferencia de notación existente entre la media y la varianza en la expresión de la función de la campana de Gauss, $(\mu$ y $\sigma^2)$, y la media y la varianza calculadas en base a un conjunto de valores, $(\bar{x}$ y $\overline{\sigma}^2)$. Esta diferencia de notación tiene su explicación, como se verá más adelante en el curso. De hecho, el primer par de parámetros se conoce con el nombre de media y varianza poblacionales, y el segundo, mediante la denominación de media y varianza muestrales.

La desviación típica y la varianza nos dan una idea de la **dispersión de los datos**. Cuanto mayor sea su valor, más dispersión existirá en los datos. Por ejemplo, supongamos que cierto *dataset* presenta tres variables numéricas enteras, A, B y C, cuyos valores vienen dados por la siguiente tabla:

A	B	C
1	1	1
1	1	2
1	2	2
2	2	2
2	2	2
2	2	2
3	2	2
3	3	2
3	3	3

¡Como podemos apreciar, la variable A está uniformemente distribuida, mientras que la variable C se encuentra muy concentrada respecto al valor 2. Si calculamos la media y la desviación típica, obtenemos los valores de la siguiente tabla.

Variable	Media	Desviación típica
A	2	0.8660
B	2	0.7071
C	2	0.5000

Como se puede apreciar, las tres variables tienen la misma media, pero la desviación típica de C es notablemente inferior a la de A, lo que indica que los datos están más concentrados en torno a la media.

Como ya hemos visto previamente, si los datos siguen (aproximadamente) una distribución normal, la media y la desviación típica son medidas especialmente importantes porque permiten **definir intervalos** en los que se concentran estadísticamente los datos. Estos intervalos se pueden usar para detectar y tratar valores anómalos.

Ejemplo práctico: cálculo de medidas de dispersión en el dataset Iris

La siguiente tabla contiene las medidas de dispersión introducidas previamente relativas a las cuatro variables numéricas del conjunto de datos de Iris.

Variable	Recorrido	Rango intercuartílico	Varianza	Desviación típica
Longitud del sépalo	3.6	1.3	0.6860	0.8281
Anchura del sépalo	2.4	0.5	0.1901	0.4359
Longitud del pétalo	5.9	3.5	3.1163	1.7653
Anchura del pétalo	2.4	1.5	0.5810	0.7622

En la tabla previa se pueden observar varios aspectos interesantes. En primer lugar, vemos que hay una gran diferencia entre variables en lo que respecta a todas las medidas de dispersión. Por ejemplo, la variable anchura del pétalo tiene un recorrido de 2.4 cm, mientras que la longitud del pétalo, de 5.9 cm. Sería de esperar, por tanto, que la segunda tuviese una mayor dispersión que la primera. Este hecho se confirma al observar los valores de la varianza y la desviación típica, considerablemente mayores en la segunda. Por otra parte, para la mayoría de las variables, vemos que los valores del recorrido y el rango intercuartílico

difieren sustancialmente. Como ya sabemos, el recorrido es una medida muy sensible a los valores extremos.

Un aspecto que conviene destacar es que, aunque anteriormente comentábamos que la varianza suele ser una cantidad mucho mayor que la desviación típica, esto no siempre ocurre. De hecho, cuando la varianza es un número entre 0 y 1, como es el caso de varias de las variables de *Iris*, la desviación típica es una cantidad mayor que la varianza.

Finalmente, fijémonos que los valores de la tabla previa concuerdan completamente con el diagrama de caja que veíamos previamente. La caja más pequeña en dicho diagrama corresponde a la anchura del sépalo, que es la variable con menor valor del rango intercuartílico (recordemos que esta cantidad se corresponde con la altura de la caja). Además, notemos que la diferencia relativa entre el recorrido y el rango intercuartílico en esta variable es la mayor de todas, por lo que tiene sentido que esta variable sea la única que presenta datos atípicos (los puntos) en el diagrama de caja.

10. Cálculo de medidas

El cálculo de las medidas que hemos revisado durante esta unidad puede ser un proceso muy laborioso si se realiza manualmente, aunque es muy conveniente que seamos capaces de realizar estos cálculos en conjuntos de datos pequeños, a fin de entender bien cómo funcionan. Sin embargo, en la vida real nos encontramos *datasets* que impiden realizar estos cálculos de manera manual, por lo que debemos apoyarnos en herramientas para realizarlos.

Por un lado, existen herramientas orientadas al **análisis de datos**, como *Microsoft Excel*, *TIBCO Spotfire*, o *Numbers*, que permiten realizar estos cálculos de manera inmediata. Por ejemplo, en *Excel* se pueden utilizar funciones como *AVERAGE()* o *STDEV()* para calcular la media y la desviación típica, respectivamente.

Por otro lado, existen lenguajes de programación orientados al tratamiento de datos. Los más utilizados son **R** y **Python**. Cada uno de ellos presenta ventajas e inconvenientes, que no discutiremos aquí. En este módulo se ha decidido utilizar R porque es un lenguaje más orientado a las técnicas estadísticas y está fuertemente vinculado al entorno académico.

La siguiente figura muestra una salida de R en la que se devuelven ciertas medidas estadísticas sobre la variable longitud del sépal.

```
> summary(sepal_length)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
4.300  5.100   5.800   5.843  6.400   7.900
```

Se ha utilizado la función *summary()*, que proporciona un conjunto de medidas estadísticas cuando se aplica sobre una variable. Se puede observar, por ejemplo, que la mediana de la variable longitud del sépal vale 5.8 cm, como ya se ha visto previamente. Posteriormente se verá cómo utilizar R para el cálculo de medidas estadísticas y otros muchos usos.

Bibliografía

- ▮ Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: data mining, inference, and prediction*. Springer Science & Business Media.
- ▮ UDC, Manuales universitarios (2012). *Fundamentos de Bioestadística*.

